



Tech Challenge – Fase 2

Pipeline Híbrido para Análise da Alfabetização no Brasil

O Tech Challenge é o projeto integrador desta fase e tem como objetivo consolidar os conhecimentos adquiridos nas disciplinas do curso. Trata-se de uma atividade obrigatória, preferencialmente desenvolvida em grupo, cuja pontuação corresponde a 90% da nota final.

Mais do que um exercício técnico, este desafio simula um **problema real enfrentado por equipes de engenharia e ciência de dados em organizações que trabalham com dados públicos em larga escala.**

Contexto do Problema

A alfabetização na infância é um dos pilares fundamentais para o desenvolvimento educacional, social e econômico de um país. Nesse contexto, o Compromisso Nacional Criança Alfabetizada surge como uma política pública que mobiliza União, estados, Distrito Federal e municípios com o objetivo de garantir que todas as crianças brasileiras estejam alfabetizadas até o final do **2º ano do ensino fundamental.**

Para apoiar a definição de parâmetros nacionais de alfabetização, o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira realizou, em 2023, a Pesquisa Alfabetiza Brasil. A partir desse estudo, foi definido o **ponto de corte de 743 pontos na escala de proficiência do Saeb**, nível a partir do qual uma criança pode ser considerada alfabetizada.

Com base nesse parâmetro, foi criado o **Indicador Criança Alfabetizada**, que expressa o percentual de estudantes que atingem esse patamar de proficiência. A meta nacional é que, **até 2030, todas as crianças brasileiras estejam alfabetizadas ao final do 2º ano do ensino fundamental.**

Entretanto, compreender os fatores que influenciam o processo de alfabetização exige mais do que a análise isolada de indicadores educacionais. É necessário **integrar diferentes fontes de dados**, incluindo:

- Metas Nacionais E Estaduais;
- Metas Municipais;
- Dados Territoriais;
- Microdados Educacionais;
- Indicadores De Desempenho.

A integração dessas fontes possibilita análises mais profundas sobre desigualdades educacionais e subsidia **políticas públicas baseadas em evidências**.

Para este desafio, você utilizará dados disponibilizados na plataforma **Base dos Dados**, especificamente a tabela do indicador de alfabetização:

Fonte de dados: [Indicador Criança Alfabetizada - Base dos Dados](#)

O Desafio

Sua equipe atuará como um **time de engenharia de dados de uma organização pública de análise educacional**. O objetivo é construir uma **pipeline híbrida de dados (Batch + Streaming)** capaz de integrar diferentes fontes relacionadas ao indicador de alfabetização, garantindo **qualidade, escalabilidade e eficiência de custos em ambiente de nuvem**.

A pipeline deverá seguir a **Arquitetura Medalhão**, com camadas:

- Bronze (dados brutos);
- Silver (dados tratados);
- Gold (dados analíticos).

Além disso, o projeto deverá considerar práticas modernas de engenharia de dados, incluindo:

- Ingestão híbrida (batch + streaming);
- Monitoramento de pipelines;
- Governança e qualidade de dados;
- Otimização de custos em cloud (finops).

Objetivo Técnico

Construir uma **pipeline de dados escalável em nuvem** que realize:

- Ingestão de diferentes fontes de dados educacionais;
- Tratamento e padronização das informações;
- Integração entre bases heterogêneas;
- Disponibilização de uma camada analítica confiável;
- Monitoramento operacional do pipeline;
- Controle de custos da infraestrutura.

Fontes de Dados

A pipeline deverá integrar as seguintes entidades:

- UF;
- Meta Alfabetização Brasil;
- Meta Alfabetização por UF;
- Meta Alfabetização por Município;
- Município;
- Dados de alunos.

Essas fontes devem ser obtidas a partir da plataforma **Base dos Dados**, que disponibiliza datasets educacionais em formato estruturado.

Arquitetura Esperada

O pipeline deverá seguir uma **arquitetura híbrida moderna**, contendo:

Ingestão Batch

Processamento periódico para ingestão de dados históricos. Exemplos:

- Dados de metas educacionais;
- Dados de municípios;
- Dados agregados nacionais.

Ingestão Streaming

Simulação de ingestão de eventos em tempo quase real, como:

- Atualização de indicadores;
- Novas medições de desempenho;
- Atualização de metas ou resultados.

Arquitetura Medalhão

A pipeline deverá implementar três camadas principais:

Bronze Layer – Raw Data. Características:

- Dados brutos ingeridos das fontes;
- Armazenamento sem transformações significativas;
- Histórico completo preservado.

Silver Layer – Dados Tratados. Transformações esperadas:

- Limpeza de dados;
- Tratamento de valores ausentes;
- Padronização de nomes e tipos;
- Validação de consistência;
- Normalização de chaves.

Nesta etapa também deve ocorrer a **integração das bases**.

Gold Layer – Camada Analítica. Criação de datasets prontos para análise, por exemplo:

- Indicador de alfabetização por município;
- Comparação entre metas e resultados;
- Evolução temporal do indicador.

Essa camada deverá estar preparada para:

- Dashboards;
- Análises estatísticas;
- Treinamento de modelos de machine learning.

Integração com fontes externas de dados (Opcional)

Você pode coletar bases externas para enriquecer ainda mais a sua base de dados. Use dados que representem contexto socioeconômico, infraestrutura educacional, território e políticas públicas. Esse tipo de enriquecimento nos dados pode permitir futuras análises como **modelos preditivos de alfabetização por município** ou **clusters de vulnerabilidade educacional**.

Dicas de fontes:

- Estrutura escolar - Censo Escolar (INEP)
- Socioeconômico - IBGE - Censo / PNAD
- Desenvolvimento humano - Atlas do Desenvolvimento Humano
- Vulnerabilidade social - Cadastro Único / Bolsa Família
- Território - IBGE
- Financiamento - FUNDEB

Regras de Qualidade de Dados

A pipeline deve incluir mecanismos de validação como:

- Verificação de duplicidade;
- Detecção de valores ausentes;
- Validação de chaves de relacionamento;
- Consistência entre tabelas.

Monitoramento da Pipeline (Opcional)

Seu pipeline deve incluir mecanismos de observabilidade. Monitoramentos esperados:

- Falhas de ingestão;
- Latência do pipeline;
- Volume de dados processados;
- Alertas de erro.

FinOps – Otimização de Custos

Além da arquitetura técnica, seu projeto deve considerar **boas práticas de FinOps**, buscando eficiência no uso da nuvem.

Algumas práticas esperadas:

- Uso eficiente de armazenamento (Parquet, particionamento);
- Otimização de queries;
- Controle de recursos computacionais;
- Estimativa de custo da arquitetura.

Seu README deve explicar:

- Como a arquitetura foi otimizada;
- Quais decisões reduzem custos operacionais.

Implementação em Cloud

A solução deve ser implementada em um ambiente de nuvem:

- AWS;
- GCP;
- Azure.

Formato da Entrega

Seu **README** deve ir além de uma explicação técnica básica. Ele deve conter:

- Contexto do problema;
- Explicação do desafio educacional e do uso do indicador de alfabetização;
- Arquitetura proposta;
- Descrição da arquitetura da solução;
- Diagrama da pipeline;
- Fluxo de dados.

Tecnologias utilizadas

Explicar:

- Ferramentas escolhidas;
- Justificativa da escolha.

Decisões arquiteturais

Apresentar trade-offs como:

- Batch vs streaming;
- Data lake vs data warehouse;
- Custo vs performance.

Monitoramento e FinOps

Explicar:

- Como o pipeline é monitorado;
- Como os custos são controlados.

Aplicação em IA

Explique como a base Gold poderia ser usada para:

- Modelos de predição de alfabetização;
- Análise de desigualdade educacional;
- Políticas públicas baseadas em dados.

Estrutura mínima do repositório

O repositório deve conter:

- Código-fonte dos pipelines;
- Estrutura clara das camadas bronze, silver e gold;
- Scripts de validação e qualidade de dados;
- Documentação técnica;
- README completo explicando a solução;

- O repositório deverá demonstrar o uso adequado de Git durante o desenvolvimento do projeto, incluindo histórico de commits que evidenciem a evolução do pipeline, mensagens de commit claras e descritivas, uso de branches para desenvolvimento de funcionalidades, criação de Pull Requests (PRs) para integração na branch principal (main ou develop) e, quando aplicável, discussões ou comentários nas PRs que justifiquem as alterações realizadas.

Vídeo Executivo (até 5 minutos)

O grupo deverá gravar um vídeo de **até 5 minutos**, no qual:

- Pelo menos um integrante apresenta o projeto;
- A apresentação seja feita em **linguagem executiva**;
- O conteúdo simule uma apresentação para **liderança ou stakeholders**.

O vídeo deve abordar:

- Problema de negócio;
- Arquitetura da solução;
- Valor da pipeline para análises educacionais;
- Potencial uso para inteligência artificial.

Boa sorte no desenvolvimento do projeto! E não deixem de discutir suas ideias com os professores ao longo do processo!



POSTECH